Процедура подготовки и инференса сетей на ускорителе LinQ TPU.

Общие положения:

Для запуска инференса нейронной сети на LinQ TPU необходимо:

- Базовые знания программирования на языке Python
- Ознакомиться с документацией к SDK
- Сформировать Программу для TPU
- Разработать программный код Предпроцессинга и Постпроцессинга данных
- Интегрировать программный код Пользовательского приложения с программным интерфейсом Ускорителя LinQ TPU (через API)

Программа TPU – программная сущность, необходимая для инференса нейронных сетей на LinQ TPU. Содержит топологию сети и веса оригинальной обученной модели нейронной сети.

Препроцессинг данных – преобразование данных Прикладного ПО в формат тензора нейронной сети.

Постпроцессинг тензора – преобразование тензора нейронной сети в формат данных Прикладного ПО.

Общий маршрут подготовки к инференсу на LinQ TPU:

[Модель обученной сети в формате ONNX] -> (SDK: квантования, компиляция) -> [Программа для TPU]

Общий маршрут инференса на LinQ TPU:

[Данные реального мира] -> (Прикладное ПО: преобразование данных и препроцессинг) -> [Входной тензор] -> (API LinQ TPU: передача/получение данных и инференс на TPU) -> [Выходной тензор] -> (Прикладное ПО: постпроцессинг и интерпретация данных)

Ссылки на SDK и документацию:

Framework (SDK) - https://cloud.lin-q.ru/s/bEqr922zr6NXHy4

tpu_framework.pdf – описание работы с SDK и пример end-to-end теста с пре- и пост- процессингами данных на языке Python

API - https://cloud.lin-q.ru/s/QcFLdkdLb71BOmm

usage_example_python_api.zip – пример программного кода для интеграции Прикладного ПО с программным стеком LinQ TPU через API Python